

Relatorio Tecnico

Diagnostico Preditivo de Hipertireoidismo com Machine Learning

Solicitante: Dr. Fernando Lima

Hospital Saude Integral - Endocrinologia

Preparado por: Fabio Igor da Silva Oliveira

Cientista de Dados - Projeto Final EBAC

Sumario Executivo

Este relatorio apresenta o desenvolvimento de um modelo preditivo de machine learning para auxiliar no diagnostico de disfuncao tireoidiana, atendendo a solicitacao do Dr. Fernando Lima, endocrinologista do Hospital Saude Integral.

O modelo final, baseado no algoritmo XGBoost, alcançou 99.87% de acuracia e, mais importante, 100% de recall para pacientes com a doenca, eliminando completamente os falsos negativos no conjunto de teste. Isso atende diretamente a exigencia clinica central do projeto: garantir que nenhum caso de disfuncao tireoidiana passe despercebido.

Resultado Principal: o modelo identificou corretamente 697 de 697 pacientes doentes no conjunto de teste, com apenas 1 falso positivo entre 58 pacientes saudaveis.

Principais Numeros

Metrica	Resultado
Acuracia geral	99.87%
AUC (capacidade discriminativa)	0.9999
Recall - pacientes doentes	100% (0 falsos negativos)
Recall - pacientes saudaveis	98% (1 falso positivo)
Variavel mais relevante	TSH (89.5% de importancia)

1. Coleta de Dados

A base de dados utilizada é amplamente reconhecida na literatura científica para problemas de diagnóstico de disfunção tireoidiana, originalmente coletada pelo Garavan Institute e J. Ross Quinlan, do New South Wales Institute, em Sydney, Austrália.

1.1 Características da Base

Atributo	Detalhe
Observações	3.772 pacientes
Variáveis originais	30 atributos
Tipo de problema	Classificação binária
Variável target	binaryClass (P = doente, N = saudável)
Distribuição da classe	92.29% doentes, 7.71% saudáveis

1.2 Nota Técnica sobre a Base

O briefing original do Dr. Fernando mencionava uma base com 9.172 observações e classificação multiclasse, contemplando múltiplas doenças da tireoide. A base efetivamente disponibilizada para este projeto é a versão clássica do dataset, com 3.772 observações e estrutura binária.

Essa é uma situação recorrente na prática profissional de ciência de dados: adaptar a abordagem a base de dados real disponível. A classificação binária (presença ou ausência de disfunção tireoidiana) ainda atende ao objetivo central do projeto, que é identificar pacientes que necessitam de atenção médica especializada.

1.3 Variáveis Disponíveis

As variáveis incluem dados demográficos (idade, sexo), histórico clínico (uso de tiroxina, cirurgia prévia, gravidez, entre outras condições) e exames laboratoriais específicos da função tireoidiana:

- TSH: Hormônio Estimulante da Tireoide
- T3: Triiodotironina
- TT4: Tiroxina Total
- T4U: Captação de Tiroxina
- FTI: Índice de Tiroxina Livre

2. Modelagem

2.1 Preparacao dos Dados

A coluna TBG foi excluida por apresentar 100% de valores ausentes. Demais valores faltantes em exames laboratoriais (entre 6% e 20% das colunas) foram tratados com a mediana, metodo robusto a valores extremos clinicos.

Foi identificado e corrigido um erro de digitacao critico: um paciente com idade registrada como 455 anos, substituido pela mediana da amostra.

Variaveis categoricas binarias (t/f) foram convertidas para formato numerico (0/1), e a variavel referral source foi tratada com one-hot encoding.

2.2 Analise Exploratoria - Principais Achados

A analise visual e estatistica revelou forte relacao entre os exames laboratoriais e o diagnostico:

Variavel	Correlacao com Diagnostico	Direcao
TSH	-0.43	Pacientes doentes tem TSH mais baixo
FTI	0.31	Pacientes doentes tem FTI mais alto
TT4	0.29	Pacientes doentes tem TT4 mais alto
T3	0.18	Pacientes doentes tem T3 mais alto

Esse padrao e clinicamente coerente: no hipertireoidismo, o excesso de hormonio tireoidiano circulante (T3, TT4, FTI elevados) suprime a producao de TSH pela hipofise, gerando o padrao de TSH baixo e hormonios perifericos altos observado nos dados.

2.3 Tratamento do Desbalanceamento

A base apresentava forte desbalanceamento (92.3% doentes vs 7.7% saudaveis) na particao de treino. Foi aplicada a tecnica SMOTE (Synthetic Minority Oversampling Technique) exclusivamente na base de treino, equilibrando as classes sem comprometer a representatividade do conjunto de teste.

2.4 Modelos Testados

Foram desenvolvidos e comparados tres algoritmos de classificacao:

Modelo	Acuracia (Teste)	AUC	Observacao
Random Forest	100%	1.0000	Resultado investigado quanto a overfitting
XGBoost	99.87%	0.9999	Modelo escolhido como final
Regressao Logistica	97.62%	0.9658	Maior interpretabilidade, menor desempenho

O XGBoost foi selecionado como modelo final por equilibrar excelente desempenho com maior robustez frente ao Random Forest, cujo resultado de 100% de acuracia, embora confirmado por validacao cruzada, foi tratado com cautela cientifica adicional.

2.5 Validacao Cruzada

Para garantir que os resultados nao decorrem de um split favoravel de dados, foi aplicada validacao cruzada com 5 folds:

Modelo	Media (5 folds)	Desvio Padrao
Random Forest	99.62%	0.0010
XGBoost	99.60%	0.0014
Regressao Logistica	96.37%	0.0224

A baixa variancia entre folds confirma a consistencia e estabilidade dos modelos de ensemble (Random Forest e XGBoost) na captura dos padroes clinicos presentes nos dados.

2.6 Otimizacao de Hiperparametros

O modelo XGBoost foi refinado por meio de GridSearchCV, otimizando especificamente para a metrica de recall, priorizando a deteccao de casos positivos conforme solicitado pelo stakeholder.

Hiperparametro	Valor Otimo
learning_rate	0.01
max_depth	4
n_estimators	100

3. Conclusões

3.1 Resultado Final

O modelo final (XGBoost otimizado) apresentou os seguintes resultados no conjunto de teste:

Metrica	Resultado
Acuracia	99.87%
AUC	0.9999
Recall - Doentes (P)	100% (0 falsos negativos)
Recall - Saudaveis (N)	98% (1 falso positivo)
Precision - Doentes (P)	100%

Zero falsos negativos no conjunto de teste: nenhum paciente com disfuncao tireoidiana foi classificado incorretamente como saudavel, atendendo diretamente ao requisito clinico critico definido pelo Dr. Fernando.

3.2 Interpretacao Clinica

A analise de Feature Importance revelou que o modelo fundamenta 89.5% de suas decisoes no nivel de TSH, seguido por uso de tiroxina (5.2%), FTI (1.8%) e TT4 (1.1%). Essa hierarquia e plenamente consistente com a pratica clinica estabelecida, na qual o TSH e reconhecido como o exame de maior sensibilidade para triagem de disfuncao tireoidiana.

A convergencia entre o padrao aprendido automaticamente pelo modelo e o conhecimento medico consolidado reforca a confiabilidade dos resultados e sua adequacao para uso como ferramenta de apoio a decisao clinica.

3.3 Recomendacoes de Uso

- O modelo deve ser utilizado como ferramenta de APOIO a decisao medica, nao como substituto do julgamento clinico.
- Recomenda-se priorizar a triagem de pacientes com TSH alterado, dado seu peso preditivo dominante.
- Para os raros casos limitrofes (proximos ao limiar de decisao do modelo), recomenda-se avaliacao clinica complementar.
- Recomenda-se validacao periodica do modelo com novos dados para garantir manutencao do desempenho ao longo do tempo.

3.4 Limitacoes do Estudo

- A base disponivel apresenta estrutura binaria, nao contemplando a granularidade multiclasse originalmente solicitada (diferenciacao entre tipos especificos de disfuncao tireoidiana).
- O elevado desempenho do modelo, embora validado por cross-validation, recomenda testes adicionais com dados de pacientes de outras instituicoes antes de uso clinico em producao.
- A coluna TBG, presente na base original, nao pode ser avaliada por ausencia total de dados.

3.5 Proximos Passos Sugeridos

- Obtencao de base de dados multiclasse para diferenciacao entre hipertireoidismo, hipotireoidismo e outras condicoes tireoidianas.

- Validacao prospectiva do modelo com pacientes reais do Hospital Saude Integral.
- Desenvolvimento de interface simples para uso pelos medicos durante a triagem inicial.

Relatorio elaborado como projeto final do curso de Ciencia de Dados - EBAC